

Mantenimiento Predictivo de Flota Vehicular

Fundamentos matematicos, fisica de falla y arquitectura de estimacion online

Este documento describe el marco cientifico del modulo de mantenimiento que estamos construyendo: que matematicas usamos, por que son las correctas, en que condiciones de datos opera el sistema desde el primer dia, y que ahorro concreto y cuantificable produce su adopcion. No es una propuesta comercial. Es la fisica del problema.

I. El problema y la asimetria de costos

II. Confiabilidad y vida util remanente

III. Fisica de falla por componente

IV. Inferencia con censura y covariables

V. Procesos de degradacion y RUL

VI. Estimacion online en regimen de streaming

VII. Marco jerarquico bayesiano

VIII. Cuantificacion del ahorro

IX. Por que este enfoque domina

El hilo conductor. Una pieza es un sistema fisico cuyo estado se degrada; la falla es el cruce de un umbral. Todo lo demas —estadistica de vida, fisica de desgaste, decision optima— son tres lentes sobre ese mismo hecho. Las tres lentes convergen en un solo motor de inferencia que corre en streaming, se alimenta de reparaciones reales y entrega distribuciones de vida residual con incertidumbre cuantificada.

El problema y la asimetría de costos

El mantenimiento de flota se gestiona hoy con calendarios fijos. Esa estrategia tiene dos modos de falla simétricos en la descripción pero radicalmente asimétricos en el costo:

- **Intervenir antes de tiempo.** Material con vida útil restante descartado. Costo directo: refacción, mano de obra, tiempo en taller.
- **Intervenir tarde.** Falla en ruta. Costo multiplicado: remolque, downtime no planeado, dano en cadena a componentes adyacentes, exposición regulatoria, carga de trabajo de taller en emergencia.

En autotransporte federal mexicano, el costo de una avería en ruta — remolque, tiempo muerto, costo de oportunidad del vehículo y del conductor— es típicamente 5 a 20 veces el costo de un servicio preventivo programado. Esta asimetría es el motor que justifica toda la matemática que sigue. La métrica correcta de cualquier modelo no es exactitud predictiva; es **costo monetario esperado**.

El error que invalida a la mayoría de los sistemas existentes. En una flota viva, la mayoría de las piezas no ha fallado al momento de observarlas: solo sabemos que su vida $T_i > t_i$ (su edad actual). Esto es censura por la derecha, y es la regla, no la excepción. Ignorarla —por ejemplo, promediar solo las piezas que fallaron— sesga la estimación hacia vidas cortas de forma grosera y produce alertas incorrectas. La verosimilitud correcta se construye con censura desde el primer día.

Confiabilidad y vida útil remanente

La función de riesgo: el objeto central

Sea $T \geq 0$ el tiempo (o km, u horas-motor) hasta la falla de un componente. Definimos la **función de riesgo instantánea**:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t < T \leq t + \Delta t \mid T > t)}{\Delta t} = \frac{f(t)}{R(t)} = -\frac{d}{dt} \ln R(t).$$

Integrar h da toda la distribución de vida:

$$R(t) = \exp\left(-\int_0^t h(u) du\right).$$

Especificar $h(t)$ equivale a especificar el modelo completo. La forma de $h(t)$ tiene física adentro: decrece durante mortalidad infantil, es constante para fallas aleatorias, y **crece** durante el desgaste. El régimen creciente es exactamente el que el mantenimiento predictivo debe anticipar.

Weibull: consecuencia del teorema de valores extremos

Weibull no es una elección de conveniencia. Se deriva del **teorema de Fisher–Tippett–Gnedenko** para distribuciones de mínimos. Un componente real es una colección de N eslabones (granos, asperezas, volúmenes elementales). Falla cuando el más débil falla: $T = \min(X_1, \dots, X_N)$. Si la cola izquierda de cada eslabón es ley de potencia, $F_X(t) \approx (t/t_0)^\beta$ para $t \rightarrow 0^+$:

$$R_T(t) = [1 - (t/t_0)^\beta]^N \xrightarrow{N \gg 1} \exp \left[- \left(\frac{t}{\eta} \right)^\beta \right], \quad \eta = t_0 N^{-1/\beta}.$$

El **parametro de forma** β selecciona el regimen: $\beta < 1$ (mortalidad infantil), $\beta = 1$ (exponencial, sin memoria), $\beta > 1$ (desgaste; mecanica tipica $\beta \in [1.5, 4]$). Consecuencia directa: el efecto de escala $\eta \propto N^{-1/\beta}$ predice que piezas mas grandes son mas debiles, resultado verificado en materiales y en la literatura tribologica.

Vida util remanente: la forma cerrada

Lo que el operador quiere saber es cuanto le queda a la pieza que ya sobrevivio hasta la edad t . Por integracion por partes:

$$\text{RUL}(t) = \mathbb{E}[T - t \mid T > t] = \frac{\int_t^\infty R(u) du}{R(t)}.$$

Para Weibull con parametros (β, η) , esto tiene forma cerrada:

$$\text{RUL}(t) = \eta e^{(t/\eta)^\beta} \Gamma\left(1 + \frac{1}{\beta}, (t/\eta)^\beta\right) - t,$$

donde $\Gamma(a, x) = \int_x^\infty w^{a-1} e^{-w} dw$ es la gamma incompleta superior. Para $\beta > 1$, la RUL decrece estrictamente con la edad: la pieza vieja tiene menos vida esperada que una nueva. La intervencion se programa cuando $R(t)$ cae a un nivel objetivo, con un buffer conservador proporcional a la incertidumbre del estimado.

Fisica de falla por componente

La estadistica dice *cundo* falla. La fisica dice *como*, permite construir predictores fisicamente fundamentados, y es lo que permite generalizar a marcas nuevas sin datos historicos propios.

Frenos — ley de Archard desde el contacto de asperezas

Dos superficies reales se tocan solo en las cimas de sus rugosidades. Bajo carga W , las asperezas se deforman plasticamente hasta que la presion de contacto iguala la dureza H del material. El area real de contacto es $A_r = W/H$, independiente del area aparente (Bowden–Tabor). Al deslizar, cada junta se rompe en distancia $\sim 2a$; con probabilidad κ arranca una particula hemisferica de volumen $\frac{2}{3}\pi a^3$:

$$\frac{dV}{dL} = \frac{\kappa}{3} \cdot \frac{W}{H} \equiv K \frac{W}{H} \implies \boxed{\frac{dh_w}{dt} = k p(t) \cdot v(t), \quad k = K/H.}$$

La energia friccional por evento de frenado es $E_{\text{frenada}} \approx \frac{1}{2}m(v_i^2 - v_f^2)$, y el desgaste acumulado es proporcional a la energia disipada total. Este acumulador — construido de IMU (desaceleracion) + GPS (velocidad) + J1939 (masa)— es el predictor fisico correcto del desgaste de balata. El odometro solo es un proxy debil.

Fatiga estructural — Miner, Basquin y conteo rainflow

El dano por carga variable se acumula segun Palmgren–Miner:

$$D = \sum_i \frac{n_i}{N_i} \geq 1 \Rightarrow \text{falla}, \quad N_i \text{ de la curva de Basquin: } \sigma_a = \sigma'_f (2N_f)^b.$$

La senal continua del IMU $a(t)$ se descompone en ciclos de amplitud por **conteo rainflow**: identifica lazos cerrados de histeresis en la senal, cada uno equivalente a un ciclo de amplitud definida. El dano acumulado en funcion de los rangos h_i de esos ciclos:

$$D_\beta = \alpha \sum_i h_i^\beta, \quad \beta \approx 3 \text{ (crecimiento de grieta)}, \quad \beta \approx 5 \text{ (iniciacion)}.$$

El rainflow se calcula en el borde (el IMU no se transmite crudo por LTE). El resultado es un indice de dano por fatiga por unidad que ningun sistema basado solo en km puede producir.

Rodamientos — Lundberg–Palmgren como caso especial de Weibull

La falla por fatiga de contacto se inicia bajo la superficie, donde el esfuerzo cortante ortogonal τ_0 es maximo. Aplicando el argumento de eslabon mas debil al volumen esforzado:

$$\ln \frac{1}{S} \propto \frac{\tau_0^c N^e V}{z_0^h} \implies \boxed{L_{10} = \left(\frac{C}{P}\right)^p, \quad p = 3 \text{ (bolas)}, \quad p = \frac{10}{3} \text{ (rodillos)}}.$$

C es dato del fabricante; P se calcula de las cargas medidas por J1939. Esta es la misma derivacion de la Seccion II aplicada al volumen subsuperficial. La vida L_{10} es exactamente la vida B_{10} de Weibull: la conexion no es coincidencia sino la misma teoria.

Aftertreatment — el quick win

J1939 difunde sin pollear: diferencial de presion del DPF (SPN 3251), nivel de DEF (SPN 1761), derate por NOx (SPN 5246), presion y temperatura de aceite (SPN 100, 175). La tendencia de ΔP , el ritmo de regeneraciones forzadas y un codigo pendiente de NOx son senales predictivas dias antes de que el sistema entre en derate. **Esta rama es totalmente alimentable hoy, sin calibracion adicional, y ataca los modos de falla mas caros del diesel moderno.**

Inferencia con datos censurados y covariables**La verosimilitud correcta**

Sea $\delta_i = 1$ si la pieza i fallo y $\delta_i = 0$ si sigue viva. La verosimilitud con censura es:

$$\mathcal{L}(\theta) = \prod_{i=1}^n h(t_i; \theta)^{\delta_i} R(t_i; \theta).$$

Cada observacion aporta su supervivencia $R(t_i)$; las que fallaron aportan ademas el riesgo $h(t_i)$ en el instante exacto. El log-verosimilitud es $\ell(\theta) = \sum_i [\delta_i \ln h(t_i; \theta) - H(t_i; \theta)]$.

Regresion de riesgos proporcionales de Cox

Para que la vida dependa de la operacion real, el modelo de riesgos proporcionales postula:

$$h(t | \mathbf{x}) = h_0(t) \exp(\boldsymbol{\beta}^\top \mathbf{x}),$$

donde $\mathbf{x}$ incluye energia de frenado acumulada, dano de Miner, severidad de ruta, carga media, marca y conductor. La verosimilitud parcial de Cox estima $\boldsymbol{\beta}$ sin especificar $h_0(t)$: en cada tiempo de falla $t_{(j)}$, la probabilidad de que falle la pieza i dado el conjunto en riesgo $\mathcal{R}_j$ es:

$$P(\text{falla } i | t_{(j)}) = \frac{e^{\boldsymbol{\beta}^\top \mathbf{x}_i}}{\sum_{k \in \mathcal{R}_j} e^{\boldsymbol{\beta}^\top \mathbf{x}_k}}.$$

El riesgo base $h_0(t_{(j)})$ se cancela. Se estima el efecto de cada covariable sobre la vida con minimas suposiciones distribucionales.

Procesos de degradacion: la RUL como distribucion completa

Cuando se mide directamente una variable de salud que degrada (ΔP_{DPF} , espesor de balata, capacidad de bateria), la RUL pasa de ser un estadistico poblacional a una distribucion condicionada al estado actual del individuo.

Proceso de Wiener. Modelo de degradacion lineal con ruido: $X(t) = x_0 + \mu t + \sigma B(t)$. La falla es el primer cruce del umbral a . Por el principio de reflexion del movimiento browniano con deriva:

$$f_{T_a}(t) = \frac{(a - x_0)}{\sigma \sqrt{2\pi t^3}} \exp\left[-\frac{(a - x_0 - \mu t)^2}{2\sigma^2 t}\right] \sim \text{IG}\left(\frac{a - x_0}{\mu}, \frac{(a - x_0)^2}{\sigma^2}\right).$$

La RUL tiene distribucion **Gaussiana Inversa**. No es un numero puntual: es una distribucion completa. Los intervalos de confianza del pronostico entran directamente en la decision de costo optimo.

La deriva μ no es un parametro libre: la fija la fisica. En frenos, $\mu = k \langle p v \rangle$ (Archard); en el DPF, μ es la tasa de acumulacion de hollin. La fisica provee el prior estructural; los datos ajustan el residuo y la incertidumbre σ .

Proceso Gamma. Para desgaste estrictamente monotono, el proceso correcto tiene incrementos no negativos: $\Delta X \sim \text{Gamma}(\alpha \Delta t, \lambda)$. La confiabilidad en t es la gamma incompleta regularizada evaluada en a .

Estimacion online en regimen de streaming

Una condicion del mundo real que el diseno debe enfrentar desde el principio: **el sistema arranca en un entorno donde la mayoría de las intervenciones son reactivas**. Las reparaciones no llegan en forma de datos limpios y etiquetados; llegan como eventos esporadicos, con ordenes de trabajo de calidad variable, en una flota que mezcla historiales incompletos con unidades nuevas sin historia alguna. El modelo no puede esperar a tener

datos maduros: debe operar desde el día uno, actualizar sus distribuciones conforme lleguen eventos, y mejorar de forma continua a medida que la flota acumula historia.

La respuesta matemática es el **filtro bayesiano recursivo**, organizado en capas a distinta cadencia. Ninguna recalcula todo.

La ecuación de Fokker–Planck como motor del filtro

El estado de degradación de cada unidad es una densidad de probabilidad que evoluciona en el tiempo. Para la dinámica de Wiener $dX = \mu dt + \sigma dW$, la densidad de creencia $p(x, t)$ obedece la **ecuación de Fokker–Planck**:

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}[\mu p] + \frac{\sigma^2}{2} \frac{\partial^2 p}{\partial x^2}.$$

El filtro opera en dos pasos por cada observación:

1. **Predicción:** propagar $p(x, t)$ según Fokker–Planck hasta el siguiente instante de observación.
2. **Corrección:** actualizar con la observación y_t por Bayes puntual: $p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1})$.

En la práctica se implementa como filtro de Kalman (lineal-gaussiano), UKF (no lineal, momentos exactos de segundo orden), o filtro de partículas (no paramétrico, a costa de costo computacional).

Sistemas reparables: el factor de calidad de Kijima

Una reparación no produce necesariamente una pieza nueva. El modelo de **edad virtual generalizada (GRP) de Kijima** parametriza la eficacia de cada intervención:

$$v_{n+1} = q(v_n + T_n),$$

donde v_n es la edad virtual antes de la n -ésima reparación y T_n el tiempo entre fallas. Con $q = 0$ la reparación es perfecta (as-good-as-new); con $q = 1$ es mínima (as-bad-as-old); $q > 0$ en la práctica refleja que la calidad de la reparación es imperfecta.

El sistema **estima q por taller, por tipo de intervención y por componente** a partir de la historia de reincidencia. Esto convierte cada orden de trabajo en una actualización del modelo y produce un scorecard de calidad de reparación que ningún sistema de mantenimiento convencional extrae.

Critico en el régimen de arranque: cuando casi todo es reactivo, la secuencia de tiempos entre fallas $T_1, T_2, \dots$ es la señal primaria de aprendizaje. El proceso de renovación generalizada de Kijima extrae de esa secuencia tanto la distribución de vida como la calidad de las intervenciones, con censura correcta sobre las piezas que aun no vuelven a fallar.

Actualización de hiperparámetros de flota: SG-MCMC

Los hiperparámetros jerárquicos (μ_β , $\tau_\bullet$, etc.) se actualizan en streaming sin recalcular toda la cadena de Markov. La clave es que el gradiente estocástico de la log-verosimilitud define una SDE cuya **distribución estacionaria es el posterior** (Stochastic Gradient Langevin Dynamics):

$$d\theta = \frac{\varepsilon}{2} \nabla_\theta \log p(\theta | \mathcal{D}) dt + \sqrt{\varepsilon} dW.$$

Minibatches de reparaciones recientes actualizan los hiperparametros sin acceder a toda la historia. Para flotas no estacionarias (cambio de flota, nueva normativa, diferente patron de carga estacional) se anade un factor de olvido exponencial sobre observaciones antiguas.

Inferencia amortizada: despliegue instantaneo para unidades nuevas

Reestimar el modelo para cada unidad nueva con MCMC es prohibitivo en produccion. La solucion es **inferencia basada en simulacion (SBI) / Neural Posterior Estimation**: entrenar una vez, offline, una red $q_\psi(\theta | x)$ que aprende el mapa datos $\rightarrow$ posterior, con pares (θ, x) generados por el simulador fisico:

$$q_\psi(\theta | x) \approx p(\theta | x).$$

En despliegue, la inferencia del posterior de una unidad nueva es un **forward pass**, no una corrida de MCMC. El simulador ya existe: la fisica de falla genera datos sinteticos etiquetados ilimitados. La red amortizada convierte la inferencia de minutos en milisegundos, lo cual es necesario para que el sistema escale a miles de unidades.

Capa	Que estima	Metodo	Cadencia
Filtrado de estado	RUL por unidad	KF / UKF / particulas	Por evento
Eventos recurrentes	Intensidad; q de Kijima	GRP / NHPP	Por reparacion
Hiperparametros de flota	$(\beta, \eta, \tau_\bullet)$ jerarquicos	HMC / SG-MCMC	Nocturno
Despliegue	Posterior de unidad nueva	SBI / forward pass	Instantaneo
Politica	Accion optima	POMDP / RL	Por decision

Marco jerarquico bayesiano de flota multimarca

Una flota real mezcla marcas, modelos, conductores y rutas. El partial pooling bayesiano anidado resuelve el problema de datos escasos por subsegmento sin sacrificar la heterogeneidad real:

$$\ln \eta_i = \underbrace{\alpha_{c,k}}_{\text{clase}} + \underbrace{\delta_{c,k,m}}_{\text{marca}} + \underbrace{\zeta_{c,k,m,j}}_{\text{modelo}} + \gamma_c^\top \mathbf{x}_i,$$

$$\alpha_{c,k} \sim \mathcal{N}(\mu_c, \tau_{\text{clase}}^2), \quad \delta \sim \mathcal{N}(0, \tau_{\text{marca}}^2), \quad \zeta \sim \mathcal{N}(0, \tau_{\text{modelo}}^2).$$

Las $\tau_\bullet$ se estiman de los datos. Si las marcas de una clase se parecen, el modelo agrupa fuerte; si difieren, desagrupa. No hay eleccion manual de cuanto pooling aplicar.

Una unidad con menos sensores (OBD vs. J1939, o sin CAN) trata la covariable faltante como variable latente y la marginaliza:

$$p(T_i | \mathbf{x}_{i,\text{obs}}) = \int p(T_i | \mathbf{x}_{i,\text{obs}}, x_{i,\text{mis}}) p(x_{i,\text{mis}} | k) dx_{i,\text{mis}}.$$

Una unidad con menos informacion produce un posterior predictivo mas ancho. La incertidumbre se propaga correctamente a la RUL y al umbral de decision. No hay imputation

manual ni descarte de unidades incompletas.

Cuantificacion del ahorro

Esta seccion deriva el ahorro esperado en forma cerrada. Los parametros numericos son estimaciones conservadoras basadas en literatura de autotransporte; se reemplazan con datos propios de la flota una vez disponibles.

Modelo de costo de referencia: mantenimiento reactivo

En un regimen puramente reactivo, la tasa de costo de largo plazo bajo el proceso de renovacion es el teorema de la teoria de renovacion aplicado al proceso de falla con distribucion Weibull(β, η):

$$g_{\text{reactivo}} = \frac{c_f}{\eta \Gamma(1 + 1/\beta)},$$

donde c_f es el costo de una falla no planificada (reparacion + downtime + remolque) y $\eta \Gamma(1 + 1/\beta) = \text{MTTF}$ es la vida media.

Modelo de costo con mantenimiento preventivo optimo

Bajo una politica de reemplazo por edad T , el costo de largo plazo por unidad de tiempo es:

$$g(T) = \frac{c_p R(T) + c_f [1 - R(T)]}{\int_0^T R(t) dt}.$$

La condicion de optimalidad $g'(T^*) = 0$ da:

$$h(T^*) \int_0^{T^*} R(t) dt - F(T^*) = \frac{c_p}{c_f - c_p}.$$

El lado izquierdo crece con T si y solo si h es creciente ($\beta > 1$), garantizando que existe un unico minimo global T^* . El **ahorro unitario por unidad de tiempo** frente a la estrategia reactiva pura es:

$$\Delta g = g_{\text{reactivo}} - g(T^*) = \frac{c_f}{\eta \Gamma(1 + 1/\beta)} - g(T^*).$$

Efecto del error de censura: el costo oculto

Si el modelo ignora la censura y estima $\hat{\eta}_{\text{sesgado}}$ en lugar del verdadero η , el intervalo de intervencion se desplaza a $\hat{T}^*$ con costo:

$$g(\hat{T}^*) = g(T^*) + \underbrace{\frac{1}{2} g''(T^*) (\hat{T}^* - T^*)^2}_{\text{costo del sesgo}}.$$

Para parametros tipicos ($\beta = 2$, fraccion censurada $\sim 70\%$), el sesgo en $\hat{\eta}$ es del orden del 30–50% (el modelo ve solo las piezas que fallaron, que son las de vida corta). El costo del

sesgo es cuadrático en el desplazamiento: un error de 30% en η se traduce en un costo de largo plazo entre 15 y 40% por encima del óptimo.

Modelo de ahorro con RUL predictiva (caso general)

El sistema predice la distribución de vida residual $p_T(\tau \mid t, \mathbf{x})$ para cada unidad individual, condicionada a su telemetría actual. La política óptima elige $T^*(t, \mathbf{x})$ que minimiza el costo esperado:

$$g^*(t, \mathbf{x}) = \min_{\tau > 0} \mathbb{E}_T \left[\frac{c_p \mathbf{1}(T > \tau) + c_f \mathbf{1}(T \leq \tau)}{\min(T, \tau)} \right].$$

La ganancia frente al preventivo óptimo de población $g(T^*)$ es:

$$\Delta g_{\text{predictivo}} = g(T^*) - \mathbb{E}_{\mathbf{x}}[g^*(t, \mathbf{x})],$$

que es estrictamente positiva cuando la variabilidad entre unidades es no trivial, porque conocer el estado individual permite intervenir más tarde en las piezas sanas y más pronto en las deterioradas.

Estimación numérica con parámetros representativos

Usamos un modelo de balata de freno como caso base, con parámetros conservadores documentados en la literatura de autotransporte:

Parámetro	Valor	Fuente
β (Weibull, balata)	2.2	Típico de desgaste abrasivo
η (vida característica)	80,000 km	Referencia OEM media
c_p (preventivo)	\$3,500 MXN	Refacción + mano de obra
c_f (correctivo)	\$28,000 MXN	c_p + downtime + remolque
Flota de referencia	50 unidades	Flota mediana típica

Con estos valores, el MTTF es:

$$\text{MTTF} = \eta \Gamma(1 + 1/\beta) = 80,000 \cdot \Gamma(1.455) \approx 71,200 \text{ km.}$$

El costo reactivo de largo plazo (por unidad, por km):

$$g_{\text{reactivo}} = \frac{28,000}{71,200} \approx 0.393 \text{ MXN/km.}$$

Resolviendo $g'(T^*) = 0$ numéricamente con los parámetros dados: $T^* \approx 58,000$ km, con:

$$g(T^*) = \frac{3,500 \cdot R(T^*) + 28,000 \cdot [1 - R(T^*)]}{\int_0^{T^*} R(t) dt} \approx 0.268 \text{ MXN/km.}$$

La reducción de costo frente a la estrategia reactiva pura es:

$$\Delta g = 0.393 - 0.268 = \mathbf{0.125 \text{ MXN/km por unidad.}}$$

Para una flota de 50 unidades con 60,000 km/año cada una:

$$\text{Ahorro anual} = 0.125 \times 60,000 \times 50 \approx \text{\$375,000 MXN/ano} \quad (\approx \text{\$19,000 USD}).$$

Esto considera solo balatas de eje delantero. Con los demas componentes (neumáticos, aceite, aftertreatment, batería), la magnitud total es típicamente 3 a 5 veces mayor, alcanzando \$1.1 a \$1.9 millones MXN por ano para una flota de 50 unidades.

El bono del aftertreatment: un DPF es un caso diferente

Un filtro de partículas forzado a reparación correctiva (derate + remolque + sustitución del DPF) cuesta entre \$35,000 y \$80,000 MXN por evento, versus una limpieza preventiva de \$2,500 MXN. Con una tasa de falla de DPF de ~ 0.15 eventos/ano por unidad en operación de ciclo severo, el ahorro esperado por unidad por ano es:

$$\Delta c_{\text{DPF}} = (0.15)(35,000 - 2,500) = \$4,875 \text{ MXN/ano}.$$

Para 50 unidades: **\$243,750 MXN/ano**. Pero el número más relevante es que un DPF correctivo equivale a 14 limpiezas preventivas, y la distinción entre los dos regímenes es exactamente lo que el sistema detecta con días de anticipación a través de la tendencia de ΔP_{DPF} .

Periodo de convergencia: arranque reactivo

La transición del régimen reactivo al predictivo no es instantánea. El modelo necesita acumular historia de fallas y reparaciones para que los parámetros Weibull converjan. El tiempo de convergencia depende del número de eventos observados por componente. Con el estimador de máxima verosimilitud bajo censura, la varianza del estimado de β es:

$$\text{Var}[\hat{\beta}] \approx \frac{\beta^2}{d},$$

donde d es el número de fallas observadas (no de unidades). Con $d = 20$ fallas, el error estándar relativo en β es $\sim 22\%$; con $d = 50$, $\sim 14\%$. Para una flota de 50 unidades con tasa de falla de 0.8/ano por componente, se acumulan 40 fallas en el primer ano: el estimador de β converge a precisión útil en los primeros 12 a 18 meses.

Durante ese periodo, el modelo opera con el prior jerárquico de clase (parámetros derivados de la literatura de fabricantes), luego va absorbiendo la historia propia. El costo de ese periodo de convergencia no es cero, pero tampoco es el costo reactivo completo: el modelo ya alerta sobre señales directas del bus (DTC, tendencia de ΔP , voltaje de batería) que no requieren historia de fallas.

Por que este enfoque domina

Contra los sistemas basados en reglas OEM

Los sistemas de reglas (alertar cuando el DTC X aparece, cambiar aceite a N km) son el punto de partida correcto pero tienen un techo bajo: no aprenden de la operación real, no distinguen severidad de ruta, no cuantifican incertidumbre, y no optimizan el momento de intervención. Son un umbral fijo en un problema que tiene estructura continua. El sistema que describimos los subsume: las reglas OEM son el prior del modelo antes de ver datos. Una vez que hay historia, el posterior toma el control.

Contra los sistemas puramente de datos (ML sin fisica)

Los sistemas de ML sin fisica necesitan miles de fallas por componente y por tipo de vehiculo para generalizar. La razon es que el espacio de configuraciones (marca, modelo, conductor, ruta, carga) es demasiado grande para que un modelo sin estructura lo cubra eficientemente. Las dos consecuencias practicas son: (1) no funcionan en flotas pequeñas o heterogeneas; (2) no generalizan a marcas nuevas sin reentrenar desde cero.

Nuestro enfoque usa la fisica (Archard, Miner, Lundberg–Palmgren) para fijar la estructura funcional de la degradacion. El ML estima los residuos y los parametros de dispersion. Esto reduce la cantidad de datos necesaria en un orden de magnitud, porque la fisica ya le dice al modelo la forma correcta de la curva de degradacion.

Contra los sistemas de supervivencia sin jerarquia

Un modelo Weibull plano (sin jerarquia) o un Cox sin partial pooling sufre el mismo problema: o bien colapsa todo en un modelo global que ignora la heterogeneidad real entre unidades, o bien ajusta un modelo separado por subsegmento y se queda sin datos. El partial pooling bayesiano es la unica solucion que interpola entre estos dos extremos de forma optima, con la cantidad de agrupamiento determinada por los datos.

Contra los sistemas sin cuantificacion de incertidumbre

Un sistema que reporta “la balata dura 30 dias mas” sin intervalo de confianza es inutilizable para decision de costo optimo. El umbral de alerta correcto depende de la razon c_f/c_p ; calcularlo requiere la distribucion de RUL, no su media. La calibracion de las probabilidades —que la frecuencia de falla entre unidades con probabilidad predicha p sea efectivamente p — es tan importante como el error medio de prediccion, y es lo que el sistema mide explicitamente.