

Mantenimiento predictivo de flota vehicular

Fundamentos fisicos, matematicos y caso economico

Un sistema que modela como se degrada cada pieza en tiempo real, cuantifica la vida residual con incertidumbre, y decide el momento optimo de intervencion – con matematicas derivadas desde primeros principios y un caso economico trazable.

Proposito de este documento. No hay pitch aqui. Lo que hay es la matematica real que subyace a lo que construimos – derivaciones desde primeros principios, no cajas negras –, y el calculo riguroso de que significa economicamente adoptar un esquema de mantenimiento predictivo sobre una flota. Para quien tiene ingenieros excelentes: aqui esta todo lo que necesitan para evaluar si el enfoque es correcto.

I	El costo real de no hacer nada: la aritmetica del mantenimiento reactivo
II	Por que el calendario fijo no es la solucion: el modelo correcto de falla
III	Distribucion de vida desde primeros principios (Weibull y teorema de extremos)
IV	Fisica de falla componente a componente
V	Inferencia con datos censurados y regresion de supervivencia
VI	Vida util remanente como distribucion: procesos de Wiener y Gamma
VII	Estimacion online bajo mantenimiento reactivo: el regimen de arranque
VIII	Modelo jerarquico bayesiano de flota multimarca
IX	Decision optima: cuando intervenir y cuanto cuesta no hacerlo
X	Cuantificacion del ahorro esperado
XI	Por que este enfoque supera a los existentes

El costo real de no hacer nada

Antes de cualquier ecuación, el problema económico. Los benchmarks que siguen provienen del Departamento de Energía de EE.UU. (US DOE), McKinsey & Company (2020), el Electric Power Research Institute (EPRI) y estudios de operadores de flota documentados entre 2022 y 2025. Se citan con precisión porque son las mismas fuentes que usan los evaluadores institucionales.

La estructura de costos del mantenimiento reactivo

Una reparación de emergencia no cuesta lo mismo que la misma reparación programada. Los componentes de costo son acumulativos:

Componente	Mecanismo	Multiplicador típico
Mano de obra	Tiempo extra, servicio nocturno o de fin de semana	1.5×–2.0×
Refacciones	Envío urgente, sin poder negociar precio	1.2×–1.4×
Dano secundario	Falla en cascada al componente adyacente	3×–5×
Tiempo muerto	Unidad varada, pérdida de ingreso por viaje	cuantificable
Grua y arrastre	Costo medio por evento en ruta	fijo por evento

El benchmark más citado y replicado: **una reparación reactiva cuesta en promedio 4.8 veces más que la misma reparación ejecutada como mantenimiento programado** (US DOE; replicado por Deloitte y operadores de flota de clase 4–8). El US DOE documenta adicionalmente:

- Reducción de costos de mantenimiento: **25%–30%** al pasar de reactivo a predictivo.
- Eliminación de fallas no planeadas: **70%–75%**.
- Reducción de tiempo muerto no planeado: **35%–45%**.
- Incremento en producción/disponibilidad: **20%–25%**.
- ROI documentado: **10:1** en implementaciones bien ejecutadas.

Fuente: US DOE, *Operations & Maintenance Best Practices Guide*, ediciones 2.0–3.0. Confirmado independientemente por EPRI (30% de reducción sobre PM periódico; 50% sobre reactivo puro) y por McKinsey & Company (2020): reducción de costos de mantenimiento 10%–40%, tiempo muerto 50%–70%.

El multiplicador de dano secundario: la pieza más subestimada

Una falla de DPF en ruta no solo cuesta el sensor de NOx o el filtro. Cuesta el derate que deja la unidad a baja potencia, la grua, el tiempo muerto, el costo de oportunidad del viaje no completado, y con frecuencia dano al turbocompresor por contaminación del aceite. El costo del componente primario puede ser la fracción más pequeña del total. El multiplicador 3×–5× de dano secundario es la razón de que las fallas en ruta de flota diésel sean desproporcionadamente caras.

Por que el calendario fijo no es la solución

Existe una alternativa inmediata al mantenimiento reactivo: el mantenimiento preventivo por calendario (cambio cada N km o M meses). Es mejor que nada, pero tiene dos fallas estructurales.

Falla 1: reemplaza piezas con vida útil remanente. IBM y operadores de flota documentan que el 30% de las intervenciones preventivas sustituyen componentes que aun tienen más del 40% de su vida útil. Eso no es mantenimiento: es desperdicio de refacciones.

Falla 2: no distingue contexto operativo. Un km en ruta de montaña con carga completa no equivale a un km en carretera plana. Una balata sometida a 200 frenadas de 80 a 0 km/h tiene más dano acumulado que una con el doble de km pero condiciones suaves. El calendario no sabe eso.

La única solución que resuelve ambas fallas es medir el estado real de cada componente y actualizar el pronóstico de vida con cada nueva observación. Eso es lo que construimos.

El modelo correcto de falla: la física como punto de partida

Sea $T \geq 0$ el tiempo (o km, u horas-motor) hasta la falla de un componente. Lo que importa físicamente no es T directamente, sino la **tasa de riesgo**:

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t < T \leq t + \Delta t \mid T > t)}{\Delta t} = \frac{f(t)}{R(t)} = -\frac{d}{dt} \ln R(t)$$

Dado que el componente llega vivo al tiempo t , $h(t)$ es la tasa a la que está fallando *ahora mismo*. Especificar $h(t)$ equivale a especificar el modelo completo:

$$R(t) = \exp\left(-\int_0^t h(u) du\right).$$

La **vida útil remanente** (RUL) – lo que el operador necesita – es:

$$\text{RUL}(t) = \mathbb{E}[T - t \mid T > t] = \frac{\int_t^\infty R(u) du}{R(t)}$$

Esto *no* es $\text{MTTF} - t$. Para riesgo creciente ($\beta > 1$, desgaste), la RUL decrece con la edad. Para riesgo constante (falla aleatoria, $\beta = 1$), la pieza no envejece y el mantenimiento por calendario no ayuda en absoluto.

Por que Weibull es la distribución inevitable: valores extremos

Un componente real es una colección de N micro-eslabones (granos, asperezas, volúmenes elementales). Falla cuando el más débil falla: $T = \min(X_1, \dots, X_N)$. Si la cola izquierda de cada eslabón es ley de potencia, $F_X(t) \approx (t/t_0)^\beta$:

$$R_T(t) = [1 - (t/t_0)^\beta]^N \xrightarrow{N \gg 1} \exp\left[-\left(\frac{t}{\eta}\right)^\beta\right], \quad \eta = t_0 N^{-1/\beta}$$

Teorema de Fisher–Tippett–Gnedenko (1928, 1943): la distribución de mínimos de variables acotadas por abajo converge a Weibull. No hay elección; hay derivación. β selecciona el régimen: < 1 mortalidad infantil, $= 1$ fallas aleatorias, > 1 desgaste. η es la vida característica.

Consecuencia física: **efecto de tamaño**. $\eta \propto N^{-1/\beta}$. Piezas más grandes (más eslabones) son intrínsecamente más débiles. Esto se mide en materiales – es la razón de que la resistencia a la fractura tenga dispersión Weibull (Weibull lo demostró estudiando resistencia de materiales, 1939–1951).

La vida residual esperada de un componente con edad t tiene forma cerrada:

$$\mathbb{E}[T \mid T > t] = \eta e^{(t/\eta)^\beta} \Gamma\left(1 + \frac{1}{\beta}, (t/\eta)^\beta\right), \quad \text{RUL}(t) = \mathbb{E}[T \mid T > t] - t$$

$\Gamma(a, x) = \int_x^\infty w^{a-1} e^{-w} dw$ es la función gamma incompleta superior. Esta es la expresión que el motor de pronóstico evalúa en línea conforme cada componente envejece.

Física de falla componente a componente

El enfoque Physics-of-Failure (PoF) modela el mecanismo de degradación desde primeros principios. Su ventaja frente a modelos puramente data-driven: generaliza a marcas y modelos sin necesitar millones de fallas por cada uno, porque la física de Archard, Miner y Lundberg–Palmgren es la misma para cualquier freno de disco.

Frenos – Ley de Archard derivada del contacto de asperezas

Dos superficies se tocan solo en las cimas de sus rugosidades. Bajo carga W , las asperezas se deforman plásticamente hasta que la presión iguala la dureza H . El área real de contacto es $A_r = W/H$, independiente del área aparente (resultado de Bowden–Tabor, 1950). Al deslizar, cada junta de radio

a se rompe en distancia $\sim 2a$; con probabilidad κ arranca una partícula hemisférica de volumen $\frac{2}{3}\pi a^3$ (criterio de Rabinowicz):

$$V = K \frac{W L}{H}, \quad K \equiv \frac{\kappa}{3}, \quad \frac{dh_w}{dt} = k p v = \frac{K}{H} p v$$

h_w = profundidad desgastada, p = presión de contacto, v = velocidad de deslizamiento.

La energía friccional es $\dot{e} = \mu_f p v$, por lo que el desgaste de balata es proporcional a la energía disipada. Cada frenada contribuye:

$$\Delta h_w \propto \frac{E_{\text{frenada}}}{H}, \quad E_{\text{frenada}} \approx \frac{1}{2} m (v_i^2 - v_f^2).$$

Se mide v de GPS y J1939/OBD, desaceleración del IMU, masa de los sensores de eje (SPN 178/179). El acumulado de energía de frenado por unidad es el predictor físico correcto, no el odómetro.

Fatiga estructural – Palmgren–Miner y conteo rainflow

Para chasis y suspensión, el IMU es el instrumento primario. El dano acumulado (regla de Miner):

$$D = \sum_i \frac{n_i}{N_i} \geq 1 \Rightarrow \text{falla}, \quad \sigma_a = \sigma'_f (2N_f)^b \quad (\text{Basquin, 1910})$$

El **conteo rainflow** (Matsuishi–Endo, 1968; norma ASTM E1049) descompone la señal del IMU en lazos cerrados de histeresis. El dano acumulado:

$$D_\beta = \alpha \sum_i h_i^\beta, \quad \beta \approx 3 \text{ (grieta)}, \beta \approx 5 \text{ (iniciación)}.$$

El rainflow se calcula en el borde; se emiten histogramas de ciclos, no señal cruda.

Rodamientos – Lundberg–Palmgren es Weibull de eslabon mas debil

La falla por fatiga de contacto se inicia bajo la superficie donde el cortante ortogonal τ_0 es máximo. Aplicando el argumento de eslabon mas debil al volumen V :

$$\ln \frac{1}{S} \propto \frac{\tau_0^c N^e V}{z_0^h} \Rightarrow L_{10} = \left(\frac{C}{P} \right)^p, \quad p = 3 \text{ bolas}, p = \frac{10}{3} \text{ rodillos}$$

C es dato del fabricante; P se calcula de las cargas medidas por J1939. Esta es la misma derivación de la Parte III aplicada al volumen subsuperficial.

Aftertreatment (DPF/DEF/SCR) – el quick win totalmente alimentable

J1939 difunde sin pollear: ΔP del DPF (SPN 3251), nivel de DEF (SPN 1761), derate por NOx (SPN 5246), presión y temperatura de aceite (SPN 100, 175), conteo de regeneraciones. La tendencia de ΔP y un código pendiente de NOx son señales predictivas días antes del derate. **Este es el primer módulo: dato totalmente alimentable hoy, sin calibración adicional, atacando las fallas mas caras del diesel moderno.**

Inferencia con datos censurados

En una flota viva, la mayoría de los componentes no ha fallado al observarlos: $T_i > t_i$. Esta es **censura por la derecha**. Ignorarla sesga la estimación hacia vidas cortas. La verosimilitud correcta es:

$$\mathcal{L}(\theta) = \prod_i h(t_i; \theta)^{\delta_i} R(t_i; \theta)$$

$\delta_i = 1$ si fallo, $\delta_i = 0$ si sigue vivo. Cada observación aporta $R(t_i)$; las que fallaron aportan además $h(t_i)$ en el instante exacto de falla.

El modelo de **riesgos proporcionales de Cox** incorpora telemetría:

$$h(t | \mathbf{x}) = h_0(t) \exp(\boldsymbol{\beta}^\top \mathbf{x})$$

En cada tiempo de falla $t_{(j)}$, con conjunto en riesgo $\mathcal{R}_j$:

$$P(\text{falla } i | t_{(j)}) = \frac{e^{\boldsymbol{\beta}^\top \mathbf{x}_i}}{\sum_{k \in \mathcal{R}_j} e^{\boldsymbol{\beta}^\top \mathbf{x}_k}}$$

El riesgo base $h_0(t)$ se cancela exactamente. Se estima $\boldsymbol{\beta}$ sin asumir ninguna forma funcional para h_0 . El vector $\mathbf{x}$ incluye: energía de frenado acumulada (Archard), dano rainflow–Miner, severidad de ruta (GPS), carga media (J1939), marca y modelo. La física reduce la dimensionalidad y la cantidad de datos necesaria.

Vida útil remanente como distribución: procesos de Wiener y Gamma

Cuando se mide una variable que degrada (espesor de balata, ΔP del DPF, capacidad de batería), el pronóstico pasa de poblacional a individual.

Proceso de Wiener. Degradación lineal con ruido: $X(t) = x_0 + \mu t + \sigma B(t)$. La falla ocurre al primer cruce del umbral a . Por el principio de reflexión del browniano con deriva:

$$f_{T_a}(t) = \frac{(a - x_0)}{\sigma \sqrt{2\pi t^3}} \exp\left[-\frac{(a - x_0 - \mu t)^2}{2\sigma^2 t}\right] \sim \text{IG}\left(\frac{a - x_0}{\mu}, \frac{(a - x_0)^2}{\sigma^2}\right)$$

La RUL tiene distribución Gaussiana Inversa. No es un número puntual: es una distribución completa, que da intervalos de confianza sobre el pronóstico.

La deriva μ no es un parámetro libre: la fija la física. En frenos, $\mu = k\langle pv \rangle$ (Archard). En el DPF, μ es la tasa de acumulación de hollín. La física provee el prior; los datos ajustan el residuo y la incertidumbre σ .

Proceso Gamma. Para desgaste estrictamente monótono: $\Delta X \sim \text{Gamma}(\alpha \Delta t, \lambda)$. La confiabilidad en t es la función gamma incompleta regularizada evaluada en el umbral.

Estimación online bajo mantenimiento reactivo: el régimen de arranque

Esta es la situación real durante los primeros meses de operación del sistema: la flota opera principalmente en modo reactivo, los datos de falla son escasos y los datos censurados dominan. El sistema no espera a tener “suficientes” datos; **aprende en tiempo real con lo que llega**.

El filtro bayesiano como ecuación maestra

La densidad de creencia $p(x, t)$ sobre el estado de salud x obedece la **ecuación de Fokker–Planck**:

$$\frac{\partial p}{\partial t} = -\frac{\partial}{\partial x}[\mu p] + \frac{1}{2} \frac{\partial^2}{\partial x^2}[\sigma^2 p]$$

Cada nueva observación y actualiza la densidad por Bayes puntual: $p(x_t | y_{1:t}) \propto p(y_t | x_t) p(x_t | y_{1:t-1})$.

Propagar la densidad con Fokker–Planck y corregirla con Bayes en cada observación es exactamente el filtro de partículas.

El factor de reparación: cuanto restaura cada intervención

No toda reparación devuelve el componente a nuevo. La **edad virtual de Kijima** modela esto: tras la i -ésima intervención, $v_i = v_{i-1} + q x_i$, con x_i el tiempo del último ciclo. El parámetro q es el **factor de restauración**: $q = 0$ es reparación perfecta, $q = 1$ es mínima (el componente queda “tan viejo como antes”), $q > 1$ es peor que antes (reparación que dana).

En el regimen de arranque con mantenimiento reactivo, cada reparacion es una observacion de alta calidad: da el tiempo exacto de falla y el tipo de intervencion. Esas observaciones son oro para calibrar q por taller y por tipo de componente. El sistema en modo reactivo **esta acumulando el dataset mas valioso posible**: fallas reales con tiempos exactos. Cuando el modelo tiene suficiente masa posterior, las alertas predictivas comienzan a desplazar a las reactivas. La transicion es gradual y medible.

Arquitectura de capas: ninguna recalcula todo

Capa	Que estima	Metodo	Cadencia
Filtrado de estado	RUL de cada unidad	KF / UKF / particulas	por evento
Eventos recurrentes	factor de reparacion q	GRP / Kijima	por reparacion
Hiperparametros de flota	$\beta, \eta, \tau_\bullet, \gamma$	HMC / SG-MCMC	nocturno
Despliegue	posterior unidad nueva	red amortizada (SBI)	instantaneo
Politica	accion optima	POMDP / RL	por decision

El filtrado es $O(1)$ por paso; los hiperparametros se refrescan en segundo plano; la inferencia de despliegue es un forward pass. El sistema escala a flotas grandes sin recalcular todo.

Modelo jerarquico bayesiano de flota multimarca

El requerimiento de cualquier operador real: el sistema debe funcionar desde el primer dia en cualquier marca, sin millones de datos por tipo de vehiculo. La solucion matematica es **partial pooling bayesiano** en tres niveles:

$$\ln \eta_i = \underbrace{\alpha_{c,k}}_{\text{clase}} + \underbrace{\delta_{c,k,m}}_{\text{marca}} + \underbrace{\zeta_{c,k,m,j}}_{\text{modelo}} + \gamma_c^\top \mathbf{x}_i$$

$$\alpha_{c,k} \sim \mathcal{N}(\mu_c, \tau_{\text{clase}}^2), \quad \delta_{c,k,m} \sim \mathcal{N}(0, \tau_{\text{marca}}^2), \quad \zeta_{c,k,m,j} \sim \mathcal{N}(0, \tau_{\text{modelo}}^2)$$

El encogimiento opera en cascada: una marca con pocos datos toma fuerza prestada de su clase, luego de la flota global. Las $\tau_\bullet$ (estimadas de los datos) controlan cuanto pooling hay – si las marcas se parecen, se agrupan fuerte; si difieren, el modelo lo detecta. No hay parametros manuales.

Por que funciona entre clases tan distintas como camion pesado, vehiculo ligero y motocicleta: **la fisica de falla es la misma** (Archard, Miner, Weibull, Lundberg–Palmgren); solo cambian los parametros. Las features fisicas transfieren entre clases aunque las marcas no se parezcan. Cuando una unidad tiene menos sensores, la covariable faltante se marginaliza automaticamente:

$$p(T_i \mid \mathbf{x}_{i,\text{obs}}) = \int p(T_i \mid \mathbf{x}_{i,\text{obs}}, x_{i,\text{mis}}) p(x_{i,\text{mis}} \mid k) dx_{i,\text{mis}}$$

Una unidad con menos informacion produce un posterior predictivo mas ancho. La incertidumbre se propaga correctamente a la RUL y al umbral de decision.

Decision optima: cuando intervenir

Intervalo optimo de reemplazo (teorema de renovacion-recompensa)

Con costo preventivo c_p y correctivo $c_f > c_p$, la tasa de costo a largo plazo bajo politica de reemplazo por edad T :

$$g(T) = \frac{c_p R(T) + c_f [1 - R(T)]}{\int_0^T R(t) dt}$$

La condicion de optimalidad $g'(T^*) = 0$ reduce a:

$$h(T^*) \int_0^{T^*} R(t) dt - F(T^*) = \frac{c_p}{c_f - c_p}$$

El lado izquierdo crece con T **solo si h es creciente** ($\beta > 1$, desgaste). Por tanto existe $T^* < \infty$ si y solo si la pieza envejece. Para $\beta = 1$ (falla aleatoria), no existe optimo finito: el reemplazo preventivo por calendario no ayuda.

Umbral de alerta sensible al costo

El modelo entrega $p = P(\text{falla en el horizonte} \mid \mathbf{x})$. La alerta optima es:

$$p > p^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

p^* no es 0.5. En el reto publico de Scania APS (UCI, 2016), $c_{FN} = 500$, $c_{FP} = 10$, de modo que $p^* \approx 2\%$: se alerta con apenas 2% de probabilidad de falla porque dejarla pasar es 50 veces mas caro. La metrica correcta de entrenamiento no es exactitud: es el costo monetario esperado.

Cuantificacion del ahorro esperado

Esta seccion construye el caso economico desde la matematica del modelo, no desde numeros redondos de marketing. Se calculan tres horizontes.

Modelo de costo total de una flota

Sea $\mathcal{F}$ una flota de N unidades. Para cada unidad i y componente j , definimos el costo total de mantenimiento en el horizonte $[0, T_H]$:

$$C_{\text{total}} = \sum_{i=1}^N \sum_j \left[c_f^{(j)} E[N_f^{(ij)}] + c_p^{(j)} E[N_p^{(ij)}] + c_d E[D^{(ij)}] \right]$$

donde $N_f^{(ij)}$ son fallas no anticipadas del componente j en unidad i , $N_p^{(ij)}$ son intervenciones preventivas, $D^{(ij)}$ son dias de tiempo muerto, y c_d es el costo diario de unidad varada.

Relacion entre estrategia y $E[N_f]$

Bajo mantenimiento reactivo puro, cada componente opera hasta la falla; el numero esperado de fallas en $[0, T_H]$ es $E[N_f] = T_H/\text{MTTF}$ (teoria de renovacion). Bajo politica predictiva optima con umbral R^* , la intervencion ocurre cuando $R(t)$ cae a R^* antes de la falla; la probabilidad de falla residual al momento de intervencion es $1 - R^* \ll 1$.

El ahorro por componente por unidad en el horizonte T_H es:

$$\Delta C^{(j)} = (c_f^{(j)} - c_p^{(j)}) \cdot \underbrace{\left(\frac{T_H}{\text{MTTF}^{(j)}} - \frac{T_H}{T^{*(j)}} \right)}_{\text{fallas evitadas}} \cdot \underbrace{(1 - \varepsilon)}_{\text{frac. anticipadas}} - c_p^{(j)} \cdot \underbrace{\frac{T_H}{T^{*(j)}}}_{\text{interv. preventivas}} + c_d \cdot \Delta D^{(j)}$$

donde ε es la tasa de falsos negativos del modelo (fallas que el sistema no anticipa), $T^{*(j)}$ es el intervalo optimo de la Parte IX, y $\Delta D^{(j)}$ es la reduccion de dias de tiempo muerto.

Parametros conservadores derivados de la literatura

Los parametros siguientes son los minimos documentados por US DOE, McKinsey (2020) y operadores de flota Clase 4–8. Se usa el rango conservador, no el optimista.

Parametro	Conservador	Medio	Fuente
Reduccion de fallas no planeadas	40%	70%	US DOE
Reduccion del costo de reparacion	25%	40%	US DOE / McKinsey 2020
Reduccion de tiempo muerto no planeado	35%	50%	US DOE / McKinsey 2020
Multiplicador costo reactivo vs preventivo	4.0×	4.8×	US DOE
Extension de vida util del activo	20%	40%	McKinsey 2020
Reduccion de inventario de refacciones	20%	35%	operadores flota

Ejercicio numerico: flota de referencia de 50 unidades

Supongamos una flota de $N = 50$ camiones de clase 6–8 en operacion en Mexico. Parametros de entrada conservadores basados en datos de mercado mexicano (2025):

Parametro	Valor
Gasto anual en mantenimiento correctivo por unidad	MXN 85 000
Dias de tiempo muerto no planeado por unidad/año	6 dias
Costo de unidad varada por dia (ingreso no generado)	MXN 12 000
Costo promedio de reparacion de emergencia (DPF, motor)	MXN 48 000
Numero de fallas criticas en ruta por unidad/año	2.8
Costo de intervencion preventiva programada (por evento)	MXN 9 000

Linea base reactiva (situacion actual):

$$\begin{aligned}
 C_{\text{reactivo}} &= N \times [C_{\text{mant}} + C_{\text{varada}} + C_{\text{emergencias}}] \\
 &= 50 \times [85,000 + 6 \times 12,000 + 2.8 \times 48,000] \\
 &= 50 \times [85,000 + 72,000 + 134,400] \\
 &= 50 \times 291,400 = \text{MXN } 14,570,000 \text{ al año}
 \end{aligned}$$

Con mantenimiento predictivo (escenario conservador, US DOE):

Aplicando los minimos documentados: 40% de reduccion en fallas no planeadas, 35% de reduccion en tiempo muerto, 25% de reduccion en costo de reparacion. Se anade el costo de las intervenciones preventivas generadas por el sistema (≈ 1.5 por unidad/año en el escenario conservador):

$$\begin{aligned}
 C_{\text{predictivo}} &= N \times [C_{\text{mant}} \times 0.75 + C_{\text{varada}} \times 0.65 + C_{\text{emergencias}} \times 0.60 + 1.5 \times c_p] \\
 &= 50 \times [63,750 + 46,800 + 80,640 + 13,500] \\
 &= 50 \times 204,690 = \text{MXN } 10,234,500 \text{ al año}
 \end{aligned}$$

Ahorro anual estimado (escenario conservador): MXN 4,335,500

Ahorro por unidad/año: MXN 86,710 $\approx$ USD 4,300

Reduccion total de costo operativo: 30%

Los escenarios medio y optimista documentados llevan el ahorro a MXN 5.8M–7.2M anuales para la misma flota. La literatura reporta ROI de 10:1 en implementaciones maduras (US DOE); el calculo anterior usa los parametros mas bajos.

Valor presente neto del programa a 5 años

Sea I_0 el costo de implementacion del sistema (hardware de captura, integracion, licencias). Con ahorro anual ΔC y tasa de descuento r :

$$VPN = -I_0 + \sum_{k=1}^5 \frac{\Delta C_k}{(1+r)^k}, \quad \Delta C_k = \Delta C \times (1+g)^{k-1}$$

donde g es la tasa de mejora anual del modelo (los modelos mejoran al acumular datos; la literatura reporta 30%–40% de incremento en ROI del año 1 al año 2).

Para $I_0 = \text{MXN } 600\,000$ (estimación conservadora de hardware + integración para 50 unidades, $\approx \text{MXN } 12\,000/\text{unidad}$), $\Delta C = \text{MXN } 4\,335\,500$, $r = 10\%$, $g = 15\%$:

$$VPN_{5a} = -600,000 + \frac{4,335,500}{1.10} + \frac{4,985,825}{1.21} + \dots \approx \text{MXN } 17.8 \text{ millones}$$

El **punto de equilibrio** se alcanza en el primer trimestre del año 1. Para una flota de 250 unidades, el mismo cálculo escala linealmente a MXN 21.7M de ahorro anual con $VPN_{5a} \approx \text{MXN } 89\text{M}$.

Componentes adicionales del ahorro no incluidos en el cálculo base

- **Extension de vida del activo.** Un camión de MXN 1.8M con 20% de extensión de vida (documentada por McKinsey) difiere MXN 360 000 en costo de reposición por unidad. Para 50 unidades con reposición promedio en 7 años: MXN 25.7M en valor diferido a valor presente.
- **Reducción de inventario.** La capacidad de anticipar demanda de refacciones reduce el inventario de seguridad 20%–35%; para una flota con MXN 800 000 inmovilizados en partes, libera MXN 160 000–280 000 en capital de trabajo.
- **Reducción de primas de seguro.** Aseguradoras en EE.UU. y Europa otorgan descuentos de 8%–15% a flotas con programas certificados de mantenimiento predictivo. En México este mercado está emergiendo.
- **Cumplimiento normativo.** Las NOMs aplicables al autotransporte federal (SICT) exigen condiciones físico-mecánicas documentadas. El sistema genera ese registro automáticamente.

Por que este enfoque supera a los existentes

Aquí la comparación es técnica, no comercial.

Frente a sistemas basados en reglas y umbrales OEM

Los sistemas actuales de telemetría (Samsara, Geotab, PeopleNet) leen el bus CAN y convierten DTC en alertas de texto. Eso es CBM de primera generación: *detección*, no *predicción*. No modelan la trayectoria de degradación; no cuantifican la incertidumbre; no calculan RUL; no optimizan el momento de intervención. La alerta llega cuando el código ya está activo, no días antes.

Frente a modelos puramente data-driven (LSTM, XGBoost)

Un LSTM entrenado en datos de flota de Navistar no generaliza a Kenworth sin reentrenamiento masivo. La razón es que los datos de telemetría cruda son altamente específicos de la plataforma. Nuestro enfoque usa la física como capa de abstracción: la energía de frenado es la misma cantidad física independientemente del OEM; el daño de Miner es independiente de la marca del chasis. El feature engineering guiado por física transfiere entre marcas y reduce la cantidad de datos necesaria en uno o dos órdenes de magnitud.

Además, un modelo data-driven puro no puede distinguir si una predicción es incierta porque el componente está en zona de riesgo alto o porque simplemente no hay datos de esa marca todavía. El modelo bayesiano lo sabe: el posterior es más ancho cuando hay menos datos, y esa incertidumbre se propaga correctamente a la decisión de intervención.

Frente a modelos de supervivencia sin física

La supervivencia pura (Kaplan–Meier, Weibull sin covariables) da estimaciones poblacionales pero no puede personalizar al individuo. Un Cox sin features físicas usa covariables de bajo poder predictivo (marca, año) y no captura la historia de carga real. La combinación PoF + Cox + jerarquía bayesiana es el enfoque state-of-the-art documentado en la literatura (Bellani et al. 2021; Nascimento & Viana, 2019; revision Theissler et al. 2021).

El diferenciador central

Ninguna otra plataforma de tracking vehicular cierra el lazo completo: sensor → feature físico (Archard, Miner, L10) → supervivencia jerárquica bayesiana → RUL con intervalo de confianza → decisión de costo óptimo → actualización continua en streaming con cada nuevo evento.

La mayoría opera hasta la tercera flecha. Nosotros operamos las cinco.